

Relatório da Atividade Prática: Aplicação de Naive Bayes para Filtragem de Spam

1. Introdução

O objetivo desta atividade prática foi a aplicação do algoritmo **Multinomial Naive Bayes** para a classificação de mensagens de texto como spam ou "ham" (mensagens legítimas). A tarefa envolveu o fluxo completo de um projeto de Ciência de Dados: carregamento de dados brutos, pré-processamento de linguagem natural (vetorização), treinamento do modelo e análise rigorosa de métricas de desempenho.

2. Metodologia

2.1 Conjunto de Dados

Utilizou-se o dataset **SMS Spam Collection**, que contém 5.572 mensagens reais. Ao contrário de datasets pré-processados, este conjunto exigiu a transformação de strings (texto) em representações numéricas para que o algoritmo pudesse realizar os cálculos probabilísticos.

2.2 Etapas Realizadas

1. **Divisão dos Dados:** O conjunto foi dividido utilizando a função `train_test_split`, reservando 80% das mensagens para o treinamento do modelo e 20% para o teste de validação.
2. **Vetorização com CountVectorizer:** Atendendo aos objetivos da atividade, utilizou-se o **CountVectorizer**. Esta ferramenta converteu as mensagens em uma matriz de contagem de tokens, construindo um vocabulário a partir das palavras presentes nas mensagens de treino.
3. **Treinamento:** O classificador MultinomialNB foi ajustado aos dados vetorizados. Este algoritmo foi escolhido por ser o padrão ouro para problemas de classificação baseados em frequências de palavras.
4. **Avaliação:** O modelo realizou previsões sobre 1.115 mensagens inéditas (conjunto de teste) para validar sua eficácia.

3. Resultados

3.1 Métricas de Desempenho

Os resultados obtidos foram extremamente satisfatórios, conforme detalhado abaixo:

- **Acurácia Geral: 99,19%**
- **Classe Legítima (0 - Ham):**
 - Precisão: 0.99
 - Recall: 1.00
 - F1-score: 1.00
- **Classe Spam (1):**

- Precisão: **1.00**
- Recall: 0.94
- F1-score: 0.97

3.2 Análise das Métricas

A métrica mais impressionante foi a **Precisão de 1.00 para a classe Spam**. Isso indica que, das mensagens classificadas como spam pelo modelo, **todas eram realmente spam**. Em um cenário real, isso significa que nenhum SMS legítimo do usuário seria movido para a pasta de lixo eletrônico por engano. O **Recall de 0.94** mostra que o modelo conseguiu capturar 94% de todos os spams existentes, deixando passar apenas uma pequena fração.

4. Discussão

A alta performance do modelo demonstra que o Naive Bayes, apesar de sua simplicidade e da "suposição ingênua" de independência entre as palavras, é altamente eficaz para classificação de textos curtos. A etapa de vetorização foi crucial, pois permitiu ao modelo identificar palavras-chave que possuem forte correlação estatística com mensagens indesejadas, como termos promocionais ou de urgência.

5. Possíveis Melhorias

Apesar do resultado próximo à perfeição, em conjuntos de dados maiores ou mais complexos (como e-mails longos), poderiam ser exploradas:

- **N-grams:** Analisar sequências de duas ou três palavras (ex: "você ganhou") em vez de palavras isoladas.
- **TF-IDF:** Aplicar uma ponderação para diminuir a importância de palavras muito frequentes que não ajudam na distinção (como conectivos).
- **Limpeza de Texto (Stopwords):** Remover pontuações e palavras vazias para reduzir o ruído nos dados.

6. Conclusão

A atividade permitiu o desenvolvimento de habilidades fundamentais em Processamento de Linguagem Natural e Aprendizado de Máquina. A implementação do CountVectorizer foi o diferencial técnico que possibilitou a transição do texto bruto para um modelo matemático de alta precisão. O resultado final de **99,19% de acurácia** valida a eficiência do Naive Bayes como uma solução robusta, rápida e confiável para o problema de filtragem de spam.